APLIKASI DOT PRODUCT PADA SISTEM TEMU BALIK INFORMASI

Laporan Tugas Besar 2 IF 2123 Aljabar Linier dan Geometri Semester I Tahun 2020/2021



Oleh:

Kelompok 8 - tasdasdadwda

Rexy Gamaliel Rumahorbo	13519010
Dionisius Darryl Hermansyah	13519058
Wilson Tandya	13519209

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA INSTITUT TEKNOLOGI BANDUNG

2020

BAB I

DESKRIPSI MASALAH

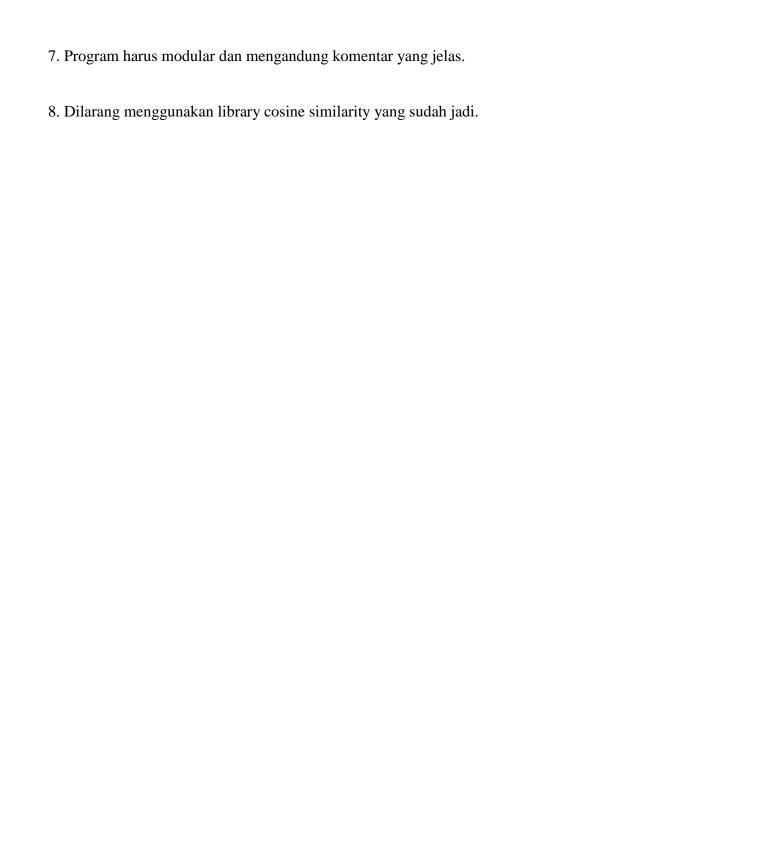
1.1. Deskripsi masalah

Pada tugas besar 2 IF2123 Aljabar Linier dan Geometri ini, akan dibuat sebuah sistem temu balik informasi dalam bentuk website dengan memanfaatkan teori *dot product* dari vektor.

1.2. Spesifikasi program

Adapun spesifikasi dari program yang akan dibuat adalah sebagai berikut:

- 1. Program mampu menerima search query. Search query dapat berupa kata dasar maupun berimbuhan.
- 2. Dokumen yang akan menjadi kandidat dibebaskan formatnya dan disiapkan secara manual. Minimal terdapat 15 dokumen berbeda sebagai kandidat dokumen. Bonus: Gunakan web scraping untuk mengekstraksi dokumen dari website.
- 3. Hasil pencarian yang terurut berdasarkan similaritas tertinggi dari hasil teratas hingga hasil terbawah berupa judul dokumen dan kalimat pertama dari dokumen tersebut. Sertakan juga nilai similaritas tiap dokumen.
- 4. Program disarankan untuk melakukan pembersihan dokumen terlebih dahulu sebelum diproses dalam perhitungan cosine similarity. Pembersihan dokumen bisa meliputi hal-hal berikut ini.
 - a. Stemming dan Penghapusan stopwords dari isi dokumen.
 - b. Penghapusan karakter-karakter yang tidak perlu.
- 5. Program dibuat dalam bentuk sebuah website lokal yang sederhana serta dibebaskan untuk menggunakan framework pemrograman website apapun. Salah satu framework website yang bisa dimanfaatkan adalah Flask (Python), ReactJS, dan PHP.
- 6. Kalian dapat menambahkan fitur fungsional lain yang menunjang program yang anda buat (unsur kreativitas diperbolehkan/dianjurkan).



BAB II

TEORI SINGKAT

2.1. Vektor

Vektor merupakan kuantitas fisik yang memiliki besar dan arah. Salah satu contoh vektor adalah vektor di R² dan R³ yang masing-masing memiliki 2 dan 3 komponen, serta dapat direpresentasikan ke dalam ruang 2 dimensi dan ruang 3 dimensi.

Sebuah vektor di ruang Rn umumnya dapat dinyatakan dengan $\mathbf{v}=(v_1,\,v_2,\,v_3,\,...,\,v_n)$. Misalkan terdapat dua buah vektor berdimensi n, $\mathbf{u}=(u_1,\,u_2,\,u_3,\,...,\,u_n)$ dan $\mathbf{v}=(v_1,\,v_2,\,v_3,\,...,\,v_n)$. Hasil penjumlahan keduanya adalah

$$\mathbf{u} + \mathbf{v} = (u_1+v_1, u_1+v_2, u_1+v_3, ..., u_1+v_n)$$

dan hasil hasil perkalian vektor **u** dengan skalar k adalah

$$k\mathbf{u} = k(v_1, v_2, v_3, ..., v_n) = (kv_1, kv_2, kv_3, ..., kv_n)$$

Norma/magnitude vektor v adalah

$$\|\mathbf{v}\| = \operatorname{sqrt}(v_1^2 + v_2^2 + v_3 + \dots + v_n^2).$$

Terdapat dua operasi perkalian antarvektor: perkalian titik dan perkalian silang. Perkalian titik/dot product dari vektor **u** dan **v** adalah

$$\mathbf{u} \cdot \mathbf{v} = u_1 v_1 + u_2 v_2 + u_3 v_3 + \dots + u_n v_n = ||\mathbf{u}|| \, ||\mathbf{v}|| \cos a$$

dengan a adalah sudut yang dibentuk **u** dan **v**. Ketidaksamaan Cauchy-Schwarz menyatakan

$$\mathbf{u} \cdot \mathbf{v} \leq ||\mathbf{u}|| \, ||\mathbf{v}||$$

Kesamaan diperoleh saat kedua vektor searah, sementara nilai $\mathbf{u} \cdot \mathbf{v} = 0$ diperoleh saat kedua vektor saling tegak lurus/orthogonal, dan nilai $\mathbf{u} \cdot \mathbf{v} = -||\mathbf{u}|| \ ||\mathbf{v}||$ diperoleh saat kedua vektor berlawanan arah.

2.2. Retrieval information

Sistem Temu-Balik Informasi atau *Information Retrieval System* merupakan kegiatan memperoleh informasi yang sesuai dengan kebutuhan dari suatu kumpulan informasi secara

otomatis. Pencarian dapat didasarkan pada teks atau pengindeksan berbasis konten. *Information Retrieval System* digunakan untuk mengurangi atau mengantisipasi *information overload*. Salah satu dari pengaplikasian *Information Retrieval System* ini adalah *search engine*.

2.3. Cosine similarity

Cosine similarity adalah besaran yang digunakan untuk mengukur seberapa mirip dokumen berdasarkan kemunculan kata terlepas dari panjang dokumen. Setiap dokumen direpresentasikan oleh vektor frekuensi yang setiap komponennya mewakili banyak kemunculan kata tertentu. Vektor frekuensi biasanya sangat panjang dan jarang (memiliki banyak nilai 0). Secara matematis, cosine similarity mengukur nilai kosinus sudut antar dua vektor yang diproyeksikan dalam ruang multidimensi. Sebuah dokumen dapat diwakili oleh ribuan atribut, masing-masing merekam frekuensi kata tertentu (kata kunci). Cosine similarity dapat memberikan urutan (ranking) berdasarkan kemiripan dokumen terhadap query yang diberikan. Cosine similarity dapat dihitung dengan persamaan berikut.

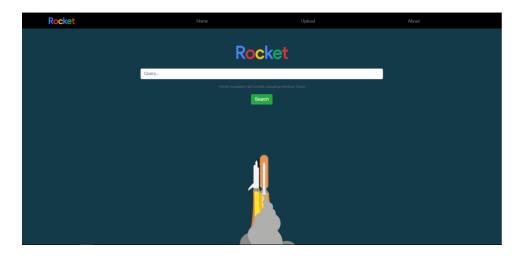
$$sim(\mathbf{Q}, \mathbf{D}) = \cos \theta = \frac{\mathbf{Q} \cdot \mathbf{D}}{\|\mathbf{Q}\| \|\mathbf{D}\|}$$

Dengan $\mathbf{Q}=(q_1\,,\,q_2\,,\,...,\,q_n\,)$ dan $\mathbf{D}=(d_1\,,\,d_2\,,\,...,\,d_n\,)$ dan $\mathbf{Q}\cdot\mathbf{D}$ adalah perkalian titik yang didefinisikan sebagai $\mathbf{Q}\cdot\mathbf{D}=(q_1\,d_1\,,\,q_2\,d_2\,,\,...,\,q_n\,d_n\,)$. Nilai kosinus 0 menyatakan bahwa kedua vektor saling ortogonal dan tidak memiliki kesamaan. Semakin dekat nilai kosinus ke 1, semakin kecil sudut antar kedua vektor yang menyatakan bahwa nilai kesamaannya semakin tinggi.

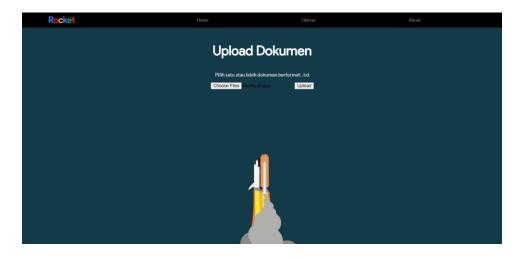
BAB III IMPLEMENTASI PROGRAM

Tampilan utama website kami ditunjukkan oleh gambar di bawah:

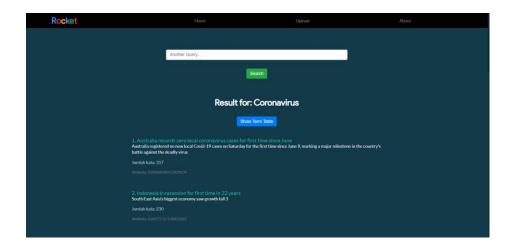
• Tampilan home page



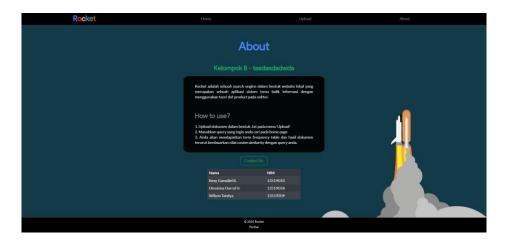
• Tampilan upload dokumen



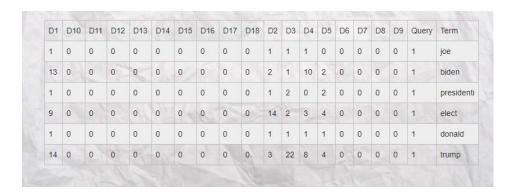
• Tampilan hasil pencarian query



• Tampilan about page



• Tampilan term frequency table



• Tampilan isi dokumen



Arsitektur website yang dibuat dibagi ke dalam 2 komponen yaitu, komponen front-end dan back-end. Komponen frontend dibuat menggunakan React.js dengan bahasa JavaScript dan dihubungkan kepada backend yang diimplementasikan menggunakan framework Flask dengan bahasa Python.

Pada pemrosesan backend ada beberapa kelas dan modul yang dibuat. Modul dan kelas tersebut berjumlah 6, dengan fungsionalitas yang berbeda-beda. Berikut ini adalah penjelasan dari modul dan kelas yang ada tersebut secara lebih rinci:

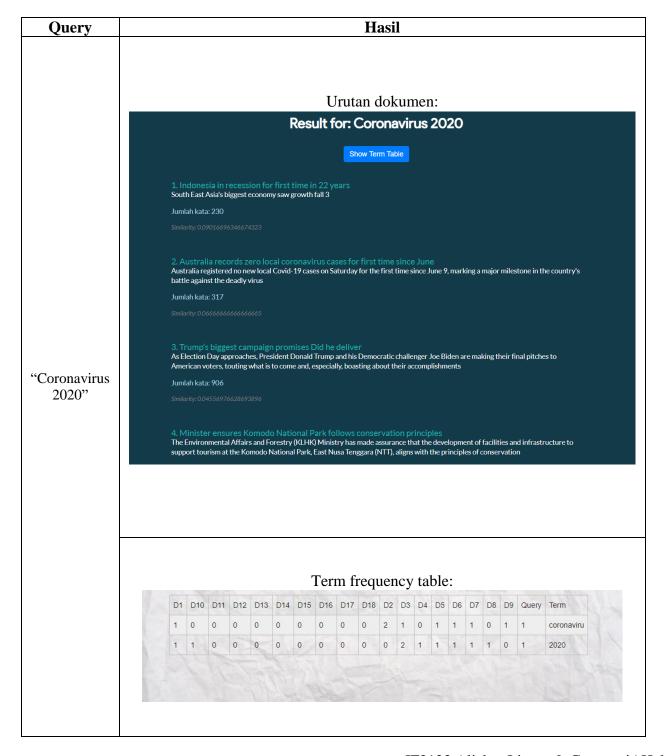
Nama Fungsi/Prosedur	Keterangan	
Main		
Berisi sebuah aplikasi Flask yang digunakan sebagai API untuk melakukan <i>fetch</i> data dari <i>front-end</i> untuk diproses dan ditampilkan. Terdapat berbagai REST API yang didefinisikan menggunakan fungsi yang terdapat pada modul-modul di bawah ini.		
Program		
query_sim	Mencari similarity dari query dari kumpulan dokumen yang ada di folder test. Output hasil query yang telah terurut berdasarkan value dalam bentuk dictionary	
term_frequency_table	Menghasilkan term_frequency_table dari query terhadap dokumen yang ada dalam format HTML	
sort_dict	Sorting sebuah dictionary berdasarkan value	
make_json	Membuat dictionary menjadi berformat json. Mereturn hasil dalam bentuk [{'title' :, 'sim':, 'first_sentence':} ,]	
Document		

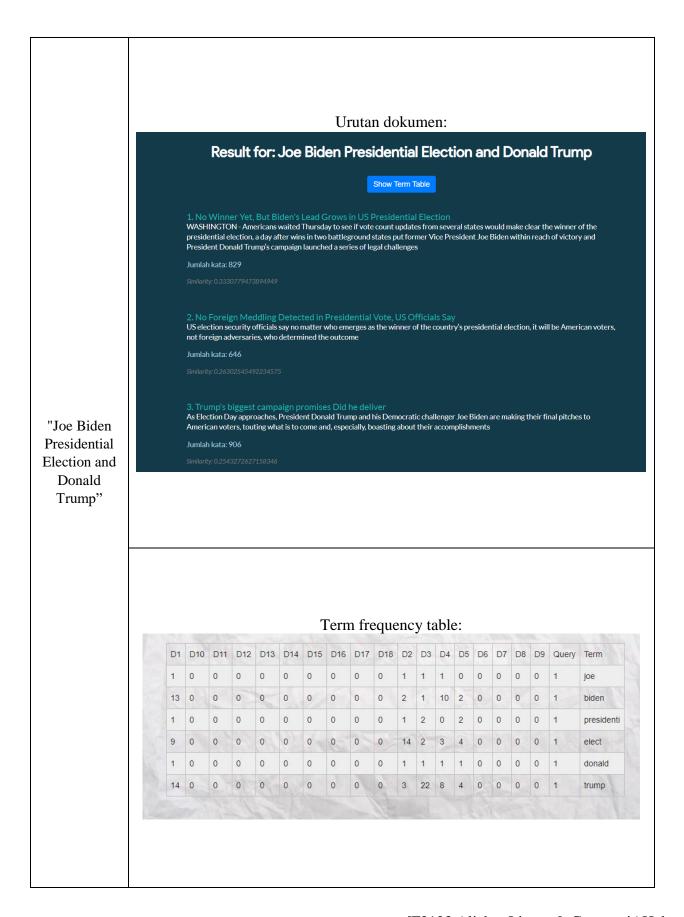
•	g berkaitan dengan dokumen. Kelas document, preprocessing document, dan menghasilkan token dari sekumpulan dokumen	
init	Inisialisasi class document dengan atribut-atributnya	
preprocess	Preprocessing text dengan menghapus stopwords dan stemming	
get_tokens	Melakukan preprocessing dan menghasilkan token dari sekumpulan dokumen	
get_first_sentence	Melakukan preprocessing dan menghasilkan kalimat pertama dari sekumpulan dokumen	
get_num_words	Melakukan preprocessing dan menghasilkan jumlah kata dari sekumpulan dokumen	
get_table	Menghasilkan tabel perhitungan kata dalam format .json. Hanya menampilkan term global dari query [{ "Term":, "Query":, "D1":, }]	
get_table_html	Menghasilkan format HTML dari tabel	
	Reader	
Berisi semua hal yang berkaitan dengan pembacaan dokumen dari file		
get_files	Mereturn semua file yang ada dalam sebuah folder	
read_txt	Membaca file .txt	
write	Writing sebuah document	
Vector		
Berisi semua hal yang berkaitan dengan vektor. Operasi vektor, menghitung magnitude, dot product, cosine similarity, dan mekonversi token kata menjadi vektor		
vectorize	Membuat vektor token kata dokumen dari sekumpulan token kata dokumen.	
term_frequency	Membuat map frekuensi kata dokumen dari sekumpulan token kata dokumen	
dot	Melakukan dot product pada vektor a dan b	
magnitude	Melakukan dot product pada vektor a dan b	
sim	Mencari nilai cosine similarity dari vektor a dan b. Prasyarat: Ukuran a dan b harus sama	

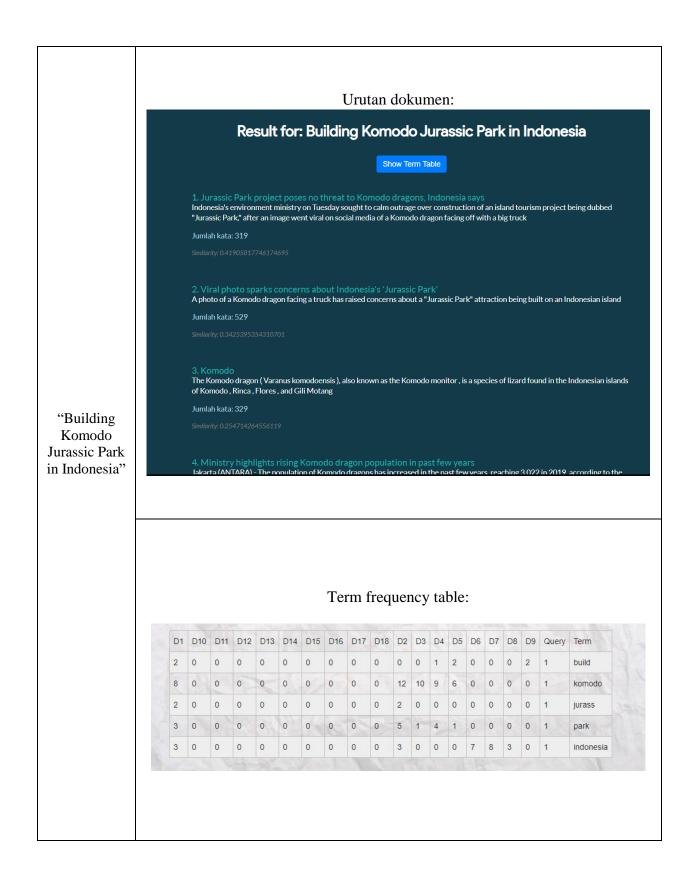
BAB IV

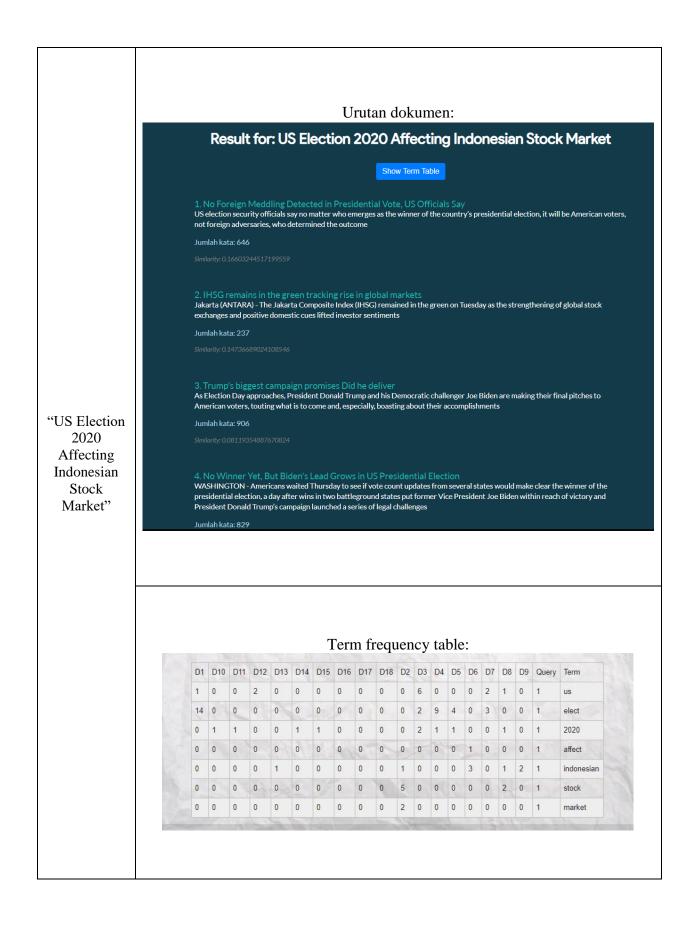
EKSPERIMEN

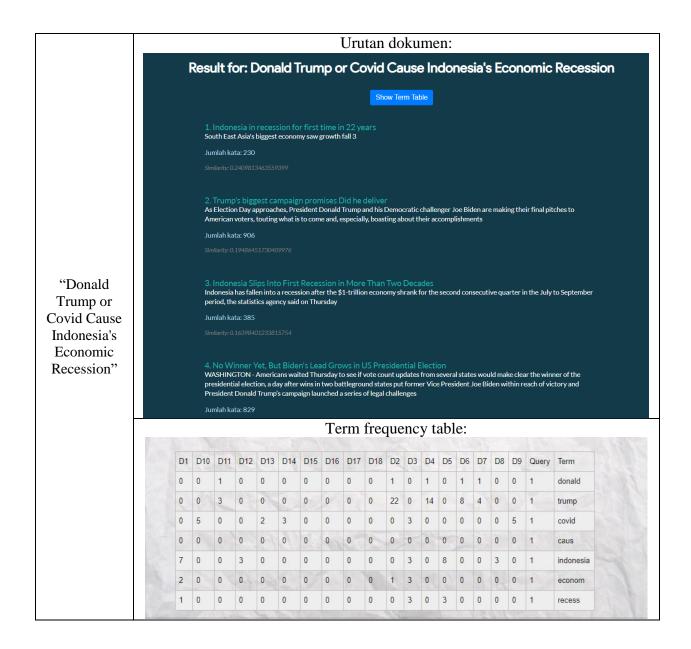
Berikut merupakan hasil eksekusi *website* dan analisis terhadap contoh-contoh dokumen yang diberikan:











BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Kesimpulan yang dapat ditarik dari tugas besar ini yaitu sebuah sistem temu balik informasi dapat dirancang menggunakan teori aljabar vektor yaitu ruang vektor dan *dot product* dengan indikator utama *cosine similarity* serta dapat diimplementasikan secara nyata dalam bentuk sebuah *website* lokal menggunakan teknologi Flask dan React.js.

5.2. Saran

Untuk pengembangan lagi kedepannya, penulis memberikan saran sebagai berikut:

- 1. Mendeploy website ke internet agar dapat diakses khalayak umum.
- 2. Memperbanyak fitur-fitur search engine pada website.

5.3. Refleksi

Melalui pengerjaan tugas besar 2 IF2123 Aljabar Linier dan Geometri ini, penulis memperoleh banyak hal baik dari segi akademik maupun non-akademik. Penulis dapat memahami materi tentang vektor serta aplikasinya secara lebih mendalam dan jelas. Melalui implementasi algoritma-algoritma secara nyata dalam program, hal ini membantu penulis dalam memahami materi yang ada. Selain itu, penulis juga belajar untuk bekerja sama dalam tim terutama dalam mengerjakan sebuah proyek serta dapat melatih skill manajemen waktu. Seluruh hasil yang telah direfleksikan ini, diharapkan dapat membantu penulis untuk berkembang ke arah yang lebih baik lagi.

DAFTAR REFERENSI

- Akeela, K. 2020. *Implementing the TF-IDF Search Engine*. Dilansir dari https://medium.com/@kartheek_akella/implementing-the-tf-idf-search-engine-5e9a42b1d30b.
- Grimberg, M. 2020. *How To Create a React* + *Flask Project*. Dilansir dari https://blog.miguelgrinberg.com/post/how-to-create-a-react--flask-project.
- Khalid, I. A. 2020. *Create A Simple Search Engine Using Python*. Dilansir dari https://towardsdatascience.com/create-a-simple-search-engine-using-python-412587619ff5.
- Munir, R. 2020. *Aplikasi Dot Product pada Sistem Temu-balik Informasi*. Bandung: Institut Teknologi Bandung.
- N.N. 2020. Tugas Besar 2 IF 2123 Aljabar Linier dan Geometri Aplikasi Dot Product pada Sistem Temu-balik Informasi Semester I Tahun 2020/2021. Bandung: Institut Teknologi Bandung.
- Symth, P. 2018. *Creating Web APIs with Python and Flask*. Dilansir dari https://programminghistorian.org/en/lessons/creating-apis-with-python-and-flask.
- Wahyuni, R. T. 2017. Penerapan Algoritma Cosine Similarity dan Pembobotan TF-IDF pada Sistem Klasifikasi Dokumen Skripsi. Semarang: Universitas Negeri Semarang.